

รายงาน

เรื่อง ระบบผู้ช่วยตอบคำถามสิทธิแรงงานไทยสำหรับผู้เริ่มทำงาน

Thai Labour-Rights Assistant for First Jobbers

จัดทำโดย

นางสาว พิชญ์สิณี วงศ์ศุภธรรม รหัสนักศึกษา 67070260

เสนอ

ดร. ณัฏฐ์ ดิลกธนากุล

รายงานนี้เป็นส่วนหนึ่งของรายวิชา 06046448 การพัฒนาแอปพลิเคชันที่ขับเคลื่อนด้วยโมเดลภาษาขนาดใหญ่

ภาคเรียนที่ 1 ปีการศึกษา 2569

บทคัดย่อ

รายงานนี้นำเสนอระบบผู้ช่วยตอบคำถามสิทธิแรงงานไทยสำหรับผู้เริ่มทำงาน ซึ่งตอบจากตัวบทกฎหมายที่มีผลใช้บังคับ ณ วันที่ 1 พฤศจิกายน 2569 พร้อมอ้างอิงมาตรา ฉบับแก้ไข และวันที่มีผลทุกครั้ง ระบบประกอบด้วยคลังเอกสารราชการ 37 ไฟล์ ตัวบทที่แบ่งเป็นรายมาตรา 1,101 ชิ้น การค้นคืนแบบผสมที่รองรับภาษาไทย และเอเจนต์ที่ใช้แบบจำลอง gemma-4-E4B-it กับเครื่องมือค้นตัวบท คำนวณเงิน และค้นอัตราทางการ โดยให้โค้ดเป็นผู้ตัดสินว่าจะตอบ ถามกลับ แก้ความเชื่อที่ผิด หรือปฏิเสธ บนคำถามที่มีเฉลย 100 ข้อ เอเจนต์มีพฤติกรรมตามที่คาดหวัง 92 ข้อ เทียบกับ 59 ข้อของแบบจำลองที่ไม่ใช้การค้นคืน และ 72 ข้อของ RAG แบบพื้นฐาน และคำนวณเงินถูกครบ 18 ข้อ ส่วนบนชุดคำถามที่ล็อกไว้ล่วงหน้าชุดล่าสุดได้ 41–42 จาก 44 ข้อ อย่างไรก็ดี เมื่อผู้จัดทำตรวจคำตอบด้วยตนเอง พบว่าถูกครบถ้วน 51 ข้อ ถูกบางส่วน 31 ข้อ และผิด 6 ข้อ

คำสำคัญ: RAG, เอเจนต์, กฎหมายแรงงานไทย, การค้นคืนภาษาไทย, การอ้างอิงแหล่งที่มา

1. บทนำ

ผู้ที่เพิ่งเริ่มทำงานมักมีคำถามพื้นฐาน เช่น ลาป่วยได้กี่วัน ค่าล่วงเวลาเท่าใด หรือถูกเลิกจ้างได้ค่าชดเชยเท่าใด แต่การหาคำตอบจากตัวบททำได้ยาก เพราะ พ.ร.บ.คุ้มครองแรงงาน พ.ศ. 2541 มีฉบับแก้ไขถึงฉบับที่ 9 ซึ่งมีผลตั้งแต่ 7 ธันวาคม 2568 และขยายสิทธิลาคลอดจาก 98 เป็น 120 วัน ขณะที่ "ฉบับเต็ม" ที่เผยแพร่ออนไลน์หลายแหล่งยังหยุดอยู่ก่อนฉบับที่ 9 แบบจำลองภาษาทั่วไปก็ตอบผิดอย่างมั่นใจ เมื่อถาม gemma-4-E4B-it [10] โดยไม่ให้ตัวบท แบบจำลองตอบว่าลาคลอดได้ 98 วันและนายจ้างจ่ายค่าจ้าง 45 วัน ซึ่งเป็นตัวเลขก่อนการแก้ไข และตอบว่าลูกจ้างที่ทำงาน 3 ปีได้ค่าชดเชย 90 วัน แทนที่จะเป็น 180 วัน

โครงงานนี้จึงมีวัตถุประสงค์ (1) ตอบจากตัวบทที่มีผลใช้บังคับ ณ วันที่กำหนด และอ้างมาตราพร้อมวันที่มีผลทุกครั้ง (2) คำนวณจำนวนเงินด้วยโค้ดแทนแบบจำลอง (3) ปฏิเสธเมื่อกฎหมายในคลังไม่ครอบคลุม ถามกลับเมื่อข้อมูลไม่พอ และแก้ไขเมื่อคำถามตั้งอยู่บนความเชื่อที่ผิด และ (4) วัดผลเทียบกับแบบจำลองที่ไม่ใช้การค้นคืนและ RAG แบบพื้นฐาน [6] ขอบเขตครอบคลุมเฉพาะตัวบทและประกาศอัตรา ไม่รวมคำพิพากษา สัญญาจ้าง หรือข้อบังคับของบริษัท ระบบนี้ไม่ใช่คำแนะนำทางกฎหมาย ผู้ใช้ควรตรวจสอบกับกรมสวัสดิการและคุ้มครองแรงงาน (สายด่วน 1546) ก่อนดำเนินการ

2. การเตรียมข้อมูล

2.1 คลังเอกสาร

คลังเอกสารมีไฟล์ทางการ 37 ไฟล์ [1, 2] ได้แก่ พ.ร.บ.คุ้มครองแรงงานฉบับรวมและฉบับแก้ไขที่ 2–9 พ.ร.บ.ประกันสังคม พ.ร.บ.เงินทดแทน กฎหมายแรงงานเฉพาะด้านอีก 6 ฉบับ และประกาศอัตรา เช่น ค่าจ้างขั้นต่ำและอัตราเงินสมทบ ทุกไฟล์บันทึกใน manifest.csv พร้อม URL วันที่มีผล สถานะ และค่า SHA-

256 และตรงกับค่าแฮชครบ 37 ไฟล์ เว็บไซต์ราชการหลายแห่งบล็อกการดาวน์โหลดด้วยสคริปต์ จึงต้องเก็บสำเนา 21 ไฟล์ที่ดาวน์โหลดซ้ำไม่ได้ไว้ในคลังโค้ด

2.2 การแบ่งตัวบทเป็นรายมาตรา

ตัวบทถูกแบ่งเป็นชิ้นละหนึ่งมาตรา ติดชื่อกฎหมาย เลขมาตรา ฉบับแก้ไขล่าสุดของมาตรานั้น และวันที่มีผล ซึ่งอ่านจากเชิงอรรถของฉบับรวม มาตรา 41 จึงอ้างฉบับที่ 9 วันที่ 7 ธันวาคม 2568 ไม่ใช่วันที่ของ พ.ร.บ. ปี 2541 ได้ 1,101 ชิ้นจากกฎหมาย 10 ฉบับ เป็นชิ้นที่มีผลใช้บังคับ 1,039 ชิ้น ซึ่งเป็นชิ้นเดียวที่ระบบค้น การดึงข้อความจาก PDF ภาษาไทยเป็นขั้นที่ยากที่สุด (ตารางที่ 1) เมื่อเทียบ 56 มาตรากับฉบับแก้ไขที่ประกาศแยก 42 มาตรามีความคล้ายอย่างน้อย 0.97 ที่เหลืออธิบายได้ทั้งหมด

ตารางที่ 1 ปัญหาที่พบในไฟล์ PDF จริงและวิธีแก้

ปัญหา	วิธีแก้
เลขเชิงอรรถติดกับเลขมาตรา เช่น "มาตรา ๔๑๒๗" คือมาตรา 41 เชิงอรรถ 27	ตัดตัวยกและเชิงอรรถออกตามขนาดตัวอักษร
ฟอนต์ของ พ.ร.บ.เงินทดแทนแสดง "ำ" เป็น "◌ำ" ได้ "มำตรำ"	สลับกลับ โดยแยก "◌ำ" จริงจากรูปแบบที่มีช่องว่างนำหน้า
ไฟล์ พ.ร.บ.จัดหางานใช้อักษรละตินแทนวรรณยุกต์ เช่น "ฝUาฝVน" คือ "ฝ่าฝืน"	ตารางแปลงอักขระเฉพาะไฟล์ อ่านจากบริบท
ฉบับรวมและฉบับแก้ไขมีผลใช้บังคับทั้งคู่ ทำให้มาตราซ้ำ	ข้ามฉบับแก้ไขที่รวมอยู่ในฉบับรวมแล้ว

2.3 ตารางอัตราทางการ

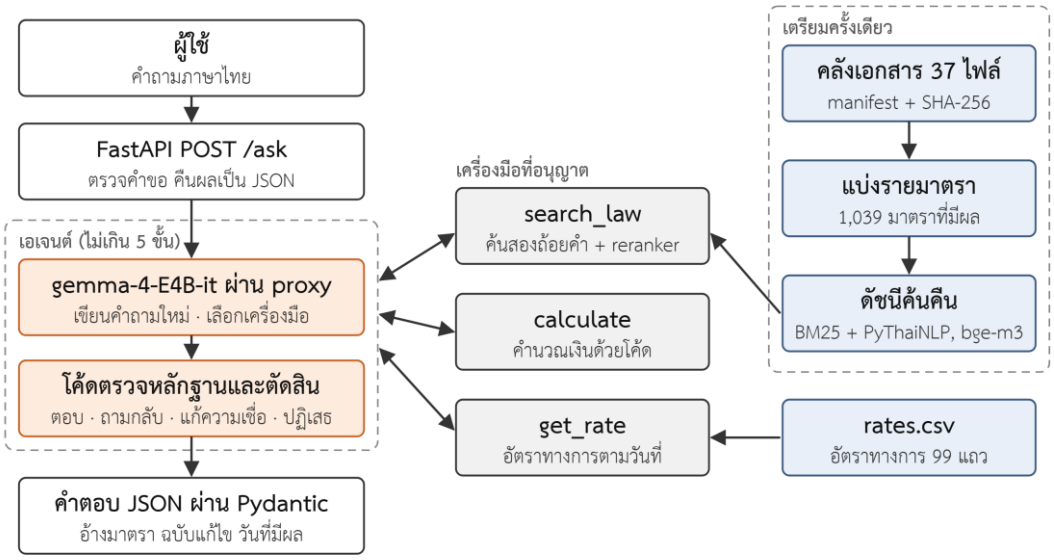
ประกาศอัตรามีลักษณะเป็นตาราง และบางไฟล์เป็นภาพสแกนหรือใช้ฟอนต์ที่อ่านไม่ได้ จึงพิมพ์ตัวเลขด้วยมือลงใน rates.csv 99 แถว แต่ละแถวมีช่วงวันที่มีผลและเอกสารต้นทาง เครื่องมือ get_rate ค้นอัตราตามวันที่ ถ้าข้อมูลไม่พอจะขอเพิ่ม เช่น เชียงใหม่ที่ค่าจ้างขั้นต่ำต่างกันตามอำเภอ และถ้าไม่มีอัตราของวันที่นั้นจะตอบว่าไม่พบแทนการเดา

3. การออกแบบระบบ

3.1 การค้นคืนข้อมูล

ภาษาไทยไม่เว้นวรรคระหว่างคำ ระบบจึงใช้ BM25 [3] ที่ตัดคำด้วย PyThaiNLP [7] คู่กับเวกเตอร์จาก BAAI/bge-m3 [5] รวมอันดับด้วย Reciprocal Rank Fusion [4] แล้วจัดอันดับใหม่ด้วย cross-encoder BAAI/bge-reranker-v2-m3 [9] ปัญหาที่พบคือภาษาพูดต่างจากภาษากฎหมายมาก มาตราเดียวกันได้คะแนน 0.035 จากถ้อยคำหนึ่ง แต่ได้ 0.999 จากอีกถ้อยคำหนึ่ง ระบบจึงให้แบบจำลองเขียนคำถามใหม่เป็นภาษากฎหมาย ค้นด้วยทั้งสองถ้อยคำ จัดอันดับใหม่ถ้อยคำละ 10 มาตรา และให้แต่ละมาตราเก็บคะแนนที่ดีที่สุด (statute_both) วิธีนี้เพิ่ม recall@5 จาก 0.841 เป็น 0.900 และใช้เวลาราว 21 วินาที

แทน 35.6 วินาทีต่อคำถามบน CPU แม้ MRR จะลดลงเล็กน้อยจาก 0.812 เป็น 0.797 แต่เอเจนต์อ่านผลค้นหลายมาตราพร้อมกัน การที่มาตราเฉลยอยู่ใน 5 อันดับแรกจึงสำคัญกว่าการอยู่อันดับแรก



ภาพที่ 1 สถาปัตยกรรมของระบบ

3.2 เอเจนต์และเครื่องมือ

เอเจนต์ใช้หลักว่า **แบบจำลองเป็นผู้อ่าน โค้ดเป็นผู้ตัดสิน** แบบจำลองเลือกคำค้นและเครื่องมือ ส่วนการตัดสินว่าจะตอบ ถามกลับ แก้ความเชื่อ หรือปฏิเสธ ทำโดยโค้ดจากประโยคที่แบบจำลองต้องยกมาจากตัวบทที่ค้นได้ ไม่ใช่จากคะแนนหรือวิจารณญาณของแบบจำลอง เครื่องมือมี 3 ตัว คือ search_law (ค้นแบบ statute_both) calculate (ค่าชดเชย ค่าล่วงเวลา ค่าทำงานในวันหยุด เงินสมทบ และเงินทดแทน ด้วยเลขคณิตแบบแม่นยำ พร้อมวิธีคิดและมาตราที่เป็นฐาน) และ get_rate ขั้นตอนการทำงานแสดงในตารางที่ 2 และภาพรวมของระบบแสดงในภาพที่ 1

ตารางที่ 2 ขั้นตอนการทำงานของเอเจนต์

ขั้น	การทำงาน	ผู้ตัดสิน
1	เขียนคำถามใหม่เป็นภาษากฎหมาย และเลือกเครื่องมือก่อนเห็นตัวบท (ไม่เกิน 5 ขั้น)	แบบจำลอง
2	ค้นด้วยทั้งสองถ้อยคำ และตัดมาตราเฉพาะกลุ่ม เช่น หญิงมีครรภ์หรือเด็ก ที่คำถามไม่ได้กล่าวถึง	โค้ด
3	ตรวจว่าผลค้นครอบคลุมคำถามหรือไม่ มาตราใดตอบได้ และความเชื่อในคำถามขัดกับตัวบทหรือไม่ โดยต้องยกประโยคจากตัวบทเป็นหลักฐาน	แบบจำลองยก โค้ดตรวจ
4	ขาดตัวเลขที่สูตรต้องใช้ ⟶ ถามกลับพร้อมหลักเกณฑ์ / สองมาตราให้ผลต่างกัน ⟶ ถามว่าเป็นกรณีใด / ไม่มีมาตราใดครอบคลุม ⟶ ปฏิเสธ / นอกนั้น ⟶ ตอบ	โค้ด

ขั้น	การทำงาน	ผู้ตัดสิน
5	ตรวจว่าตัวเลขทุกตัวมาจากตัวบท ผลของเครื่องมือ หรือคำถาม แล้วส่งคำตอบ JSON ที่ผ่าน Pydantic	โค้ด

การออกแบบนี้มาจากความล้มเหลวระหว่างพัฒนา เมื่อแบบจำลองเห็นตัวบทก่อนจะตอบเลยโดยไม่เรียกเครื่องมือ ไม่มีเกณฑ์คะแนนขั้นต่ำใดแยกคำถามนอกขอบเขตได้ (เกณฑ์ที่ดีที่สุดปฏิเสธคำถามนอกขอบเขต 16 จาก 18 ข้อ แต่ปฏิเสธคำถามที่ตอบได้ไปด้วย 12 จาก 82 ข้อ) และเมื่อให้แบบจำลองถามกลับเอง มักถามรายละเอียดที่ไม่จำเป็น ระบบให้บริการที่ POST /ask ของ FastAPI และชุดทดสอบอัตโนมัติ 155 รายการผ่านทั้งหมด ด้านความปลอดภัย คีย์และที่อยู่ของ proxy อ่านจากตัวแปรสภาพแวดล้อม ไม่มีในคลังโค้ด ทุกการเรียกใช้ temperature=0 แบบจำลองเรียกได้เฉพาะเครื่องมือที่อนุญาต อาร์กิวเมนต์ตรวจด้วย Pydantic ที่ไม่รับฟิลด์เกิน ถ้าผิดโค้ดจะคืนข้อความผิดพลาดให้แบบจำลองแก้แทนการหยุดทำงาน ค้นได้ไม่เกิน 2 ครั้งต่อคำถาม คำตอบที่ไม่ผ่าน schema ส่งกลับให้แก้ได้อีก 2 ครั้ง และ prompt ระบุว่าผลของเครื่องมือเป็นข้อมูล ไม่ใช่คำสั่ง

4. การประเมินผล

4.1 ชุดคำถามและผลการค้นคืน

ชุดคำถามหลักมี 100 ข้อ ได้แก่ สิทธิทั่วไป 30 ข้อ คำถามกับดักที่มีตัวเลขล้าสมัย 20 ข้อ การคำนวณ 18 ข้อ นอกขอบเขต 18 ข้อ ต้องถามกลับ 8 ข้อ และต้องแก้ความเชื่อ 6 ข้อ แต่ละข้อมีมาตราเฉลย ข้อความหลักฐาน และพฤติกรรมที่คาดหวัง และมีคำถามควบคุมอีก 14 ข้อเพื่อจับการถามกลับหรือแก้ไขโดยไม่จำเป็น ผลการค้นคืนบนคำถาม 82 ข้อที่มีมาตราเฉลยแสดงในตารางที่ 3 การตัดคำภาษาไทยเพิ่ม recall@5 จาก 0.018 เป็น 0.504 และการรวมอันดับแบบผสมต่ำกว่าเวกเตอร์อย่างเดียวจนกว่าจะจัดอันดับใหม่

ตารางที่ 3 ผลการค้นคืนบนคำถาม 82 ข้อ

วิธีการค้นคืน	recall@5	MRR
BM25 ตัดคำตามช่องว่าง (baseline)	0.018	0.015
BM25 + PyThaiNLP	0.504	0.357
เวกเตอร์ bge-m3	0.764	0.683
แบบผสม (RRF)	0.713	0.579
แบบผสม + จัดอันดับใหม่ 50 อันดับแรก	0.841	0.812
statute_both (ใช้ในเอเจนต์)	0.900	0.797

4.2 ผลคำตอบ

ตารางที่ 4 ตรวจด้วยโค้ดเทียบกับป้ายเฉลย ยกเว้นแถว LLM judge ซึ่งใช้ gemma-4-E4B-it ตัวเดียวกับที่ตอบ ตัวหาร 58 คือข้อที่มีตัวเลขเฉลย 74 คือข้อที่มีมาตราเฉลยลบข้อที่ต้องถามกลับ 92 คือข้อที่ไม่ต้องถามกลับ และ 10 คือข้อที่ป้ายกำหนดให้แก้ความเชื่อ (ข้อแก้ความเชื่อ 6 ข้อและกับดัก 4 ข้อ) เอเจนต์

คือรุ่นสุดท้ายหลังแก้ไขครบ 4 รอบในหัวข้อ 4.3 การอ้างอิงนับว่าถูกเมื่อตรงกับมาตราเฉลย หรือสำหรับอัตราตามกฎหมาย คือประกาศที่ป้ายเฉลยระบุ

ตารางที่ 4 ผลคำตอบของระบบทั้งสามบนคำถาม 100 ข้อ

ตัวชี้วัด	ไม่ค้นคืน	RAG	เอเจนต์
พฤติกรรมตามที่คาดหวัง	59/100	72/100	92/100
ตัวเลขที่ถามถูก และไม่ใช้ตัวเลขล้าสมัย	7/58	30/58	55/58
คำนวณถูก	2/18	2/18	18/18
อ้างมาตราหรือประกาศเฉลย	17/74	48/74	70/74
LLM judge ตัดสินว่าถูก	13/74	41/74	64/74
ปฏิเสธคำถามนอกขอบเขต	10/18	18/18	16/18
ถามกลับเมื่อจำเป็น	7/8	2/8	6/8
ถามกลับเมื่อไม่จำเป็น (ยิ่งน้อยยิ่งดี)	28/92	1/92	2/92
แก้ความเชื่อได้ถูกเนื้อหา	0/10	2/10	8/10

เอเจนต์ดีกว่าอีกสองระบบในเกือบทุกด้าน (ตารางที่ 4) ที่ชัดที่สุดคือการคำนวณ ซึ่ง RAG ยังผิดเกือบทั้งหมดแม้ได้ตัวบทที่ถูก ส่วนแบบจำลองที่ไม่ใช้การค้นคืนดูเหมือนถามกลับได้ดี เพราะถามกลับแทบทุกข้อ ผลแปรผันเล็กน้อยระหว่างการรันแม้ตั้ง temperature=0 การรันทั้งสามระบบใหม่บนเครื่องใหม่ได้พฤติกรรมตามที่คาดหวัง 58, 73 และ 91 ข้อ เมื่อผู้จัดทำตรวจคำตอบทั้ง 100 ข้อของเอเจนต์หลังแก้ไขรอบที่ 3 ด้วยตนเอง พบว่าถูกต้อง 51 ข้อ ถูกบางส่วน 31 ข้อ ผิด 6 ข้อ และไม่แน่ใจ 12 ข้อ ซึ่งเป็นคำถามนอกขอบเขตทั้งหมด LLM judge ไม่ให้ผ่านคำตอบที่ผิดเลย (0 จาก 5 ข้อที่ตรวจ) แต่ให้ผ่านคำตอบที่ถูกบางส่วน 20 จาก 23 ข้อ แสดงว่าตัวชี้วัดอัตโนมัติวัดความครบถ้วนไม่ได้

4.3 การทดสอบบนชุดคำถามที่ล็อกไว้

ระบบถูกปรับบนคำถาม 100 ข้อชุดเดียวกับที่ใช้วัด คะแนนจึงอาจสูงเกินจริง การแก้ไขแต่ละรอบจึงวัดบนชุดคำถามใหม่ที่ล็อกค่า SHA-256 ไว้ก่อนเขียนโค้ดแก้ไข โค้ดก่อนและหลังแก้รันอย่างละ 3 ครั้ง รวม 5 ชุด 242 ข้อ (ตารางที่ 5)

ตารางที่ 5 พฤติกรรมตามที่คาดหวังบนชุดคำถามที่ล็อกไว้ (ช่วงต่ำสุด–สูงสุดของ 3 ครั้ง)

ชุด	ข้อ	สิ่งที่แก้ในรอบนั้น	ก่อน ⟶ หลัง
heldout	30	ไม่มี (ตรวจเอเจนต์ที่ปรับแล้วครั้งแรก)	22–23
heldout2	60	จุดอ่อนที่พบจากการตรวจครั้งแรก	46 ⟶ 48–50
heldout3	60	ถามกลับตามตัวบท ตัวเลขทุกตัวต้องมีที่มา	48–51 ⟶ 50
heldout4	48	ถามตัวเลขที่สูตรคำนวณต้องใช้	45 ⟶ 44–45
heldout5	44	แก้ตามผลการตรวจโดยมนุษย์	40–41 ⟶ 41–42

ชุดแรกได้ราวร้อยละ 73–77 เทียบกับร้อยละ 92 บนชุดที่ใช้ปรับ การแก้ไขแต่ละรอบเพิ่มคะแนนเล็กน้อย แต่ชุดขนาด 30–60 ข้อมีช่วงความเชื่อมั่น Wilson ร้อยละ 95 [8] กว้างราว 20–30 จุด ความต่างส่วนใหญ่จึงอยู่ในระดับความแปรปรวนปกติ และบางการแก้ไขแลกความล้มเหลวแบบหนึ่งกับอีกแบบ เช่น รอบที่ 4 ถามกลับเมื่อจำเป็นดีขึ้น แต่ถามกลับเมื่อไม่จำเป็นเพิ่มจาก 0/34 เป็น 3/34

โค้ด ข้อมูล และผลทุกชุด (โฟลเดอร์ eval/results/) อยู่ที่ https://github.com/ritsupaintblu/Thai_labour_rights_assistant_for_first_jobber และรันซ้ำได้ตาม README

5. ตัวอย่างกรณีสำเร็จและล้มเหลว

สำเร็จ: "ทำงานมา 3 ปี 2 เดือน เงินเดือน 25,000 บาท ถูกเลิกจ้าง ได้ค่าชดเชยอย่างน้อยเท่าไร" เอเจนต์เรียก calculate ได้ 150,000 บาท พร้อมวิธีคิด "25,000 / 30 x 180 = 150,000 บาท" และอ้างมาตรา 118 (3) ซึ่ง calculate คืนเป็นฐานทางกฎหมายเสมอ แม้การค้นจะไม่พบมาตรานั้น

ล้มเหลว: เลือกสูตรผิด คำถามเรื่องเงินเดือน 18,000 บาท ถูกเรียกมาทำงานวันหยุดประจำสัปดาห์ 8 ชั่วโมง คำตอบที่ถูกคือ 1 เท่าของค่าจ้างรายชั่วโมงตามมาตรา 62 เท่ากับ 600 บาท แต่เอเจนต์เลือกสูตรค่าล่วงเวลาในวันหยุด 3 เท่าตามมาตรา 63 และตอบ 1,800 บาท การคำนวณถูกตามสูตร แต่สูตรถูกเลือกจากมาตราที่ค้นได้แทนที่จะเทียบกับเงื่อนไขในคำถาม

ล้มเหลว: ปฏิเสธพร้อมข้อความที่ไม่จริง คำถาม "เพิ่งเริ่มงานเดือนแรก มีสิทธิลาได้กี่วันบ้าง" ควรถามกลับว่าเป็นการลาประเภทใด พร้อมสรุปว่าลาป่วยได้เท่าที่ป่วยจริงและลากิจได้ไม่น้อยกว่า 3 วันทำงานต่อปี แต่เอเจนต์ตอบว่า "กฎหมายที่ระบบมีไม่ได้บังคับเรื่องสิทธิวันลาเริ่มต้นงาน" ซึ่งไม่จริง การปฏิเสธที่พยายามให้เหตุผลจึงอาจกลายเป็นการให้ข้อมูลผิดเสียเอง

6. ข้อจำกัดและงานในอนาคต

- ไม่รวมกฎหมายที่เปลี่ยนหลังวันที่ 1 พฤศจิกายน 2569 ต้องเพิ่มใน manifest ด้วยมือโดยติดตามราชกิจจานุเบกษา
- แบบจำลองขนาดเล็กยังเลือกสูตรผิดในบางกรณี และถามตัวเลขของผู้ใช้ในคำถามที่ถามเพียงอัตราหรือเพดาน
- ผู้จัดทำคนเดียวเขียนและติดป้ายคำถามทุกข้อ รวมทั้งพิมพ์ตัวเลขจากไฟล์สแกน ผลจึงบอกทิศทางมากกว่าความแม่นยำที่แท้จริง
- LLM judge เป็นแบบจำลองเดียวกับที่ตอบและวัดความครบถ้วนไม่ได้ และผลต่างกันระหว่างการรันแม้ใช้ temperature=0
- ค่าชดเชยคิดค่าจ้างรายวันเป็นเงินเดือนหาร 30 ซึ่งกฎหมายไม่ได้กำหนดไว้

- ผลของเครื่องมือไม่ได้ห่อด้วยตัวคั่นข้อมูลที่ไม่น่าเชื่อถือ ยอมรับได้เพราะคลังเป็นเอกสารราชการที่ตรวจค่าแฮช แต่ต้องเพิ่มถ้าใช้ข้อมูลจากเว็บ
- ใช้เวลา 20–40 วินาทีต่อคำถามบน CPU ส่วนใหญ่เป็นการจัดอันดับใหม่ ควรใช้ GPU หรือ reranker ที่เล็กลง

7. สรุป

แบบจำลองขนาดเล็กอย่าง gemma-4-E4B-it ตอบคำถามสิทธิแรงงานไทยได้ดีขึ้นชัดเจนเมื่อมีสามองค์ประกอบ คือ คลังตัวบทที่มีผลใช้บังคับพร้อมฉบับแก้ไขและวันที่ การค้นคืนที่รองรับทั้งภาษาไทยและภาษากฎหมาย และการย้ายการตัดสินใจและการคำนวณจากแบบจำลองไปไว้ในโค้ด พฤติกรรมตามที่คาดหวังเพิ่มจาก 59 เป็น 92 จาก 100 ข้อ และการคำนวณถูกจาก 2 เป็น 18 จาก 18 ข้อ อย่างไรก็ดี ผลบนชุดคำถามที่ล็อกไว้ต่ำกว่าบนชุดที่ใช้พัฒนา และความผิดพลาดที่เหลือยังเป็นความเสี่ยงต่อผู้ใช้จริง ระบบจึงเหมาะเป็นเครื่องมือช่วยค้นและชี้มาตราที่เกี่ยวข้อง มากกว่าใช้แทนคำปรึกษาจากผู้เชี่ยวชาญ

เอกสารอ้างอิง

[1] กรมสวัสดิการและคุ้มครองแรงงาน. พระราชบัญญัติคุ้มครองแรงงาน พ.ศ. 2541 (ฉบับรวมถึงฉบับที่ 9). สืบค้นจาก https://legal.labour.go.th/images/law/Protection2541/2568_protectionpdf.pdf

[2] รายการเอกสารกฎหมายและประกาศอัตราทั้ง 37 ไฟล์ พร้อม URL วันที่มีผล และค่า SHA-256 อยู่ในไฟล์ data/manifest.csv ของโครงงาน

[3] Robertson, S., & Zaragoza, H. (2009). The probabilistic relevance framework: BM25 and beyond. Foundations and Trends in Information Retrieval, 3(4), 333–389.

[4] Cormack, G. V., Clarke, C. L. A., & Büttcher, S. (2009). Reciprocal rank fusion outperforms Condorcet and individual rank learning methods. In Proceedings of SIGIR 2009 (pp. 758–759).

[5] Chen, J., Xiao, S., Zhang, P., Luo, K., Lian, D., & Liu, Z. (2024). BGE M3-Embedding: Multi-lingual, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. arXiv:2402.03216.

[6] Lewis, P., Perez, E., Piktus, A., et al. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. In Advances in Neural Information Processing Systems 33.

[7] Phatthiyaphaibun, W., et al. (2023). PyThaiNLP: Thai natural language processing in Python. In Proceedings of the 3rd Workshop for NLP Open Source Software (NLP-OSS 2023).

[8] Wilson, E. B. (1927). Probable inference, the law of succession, and statistical inference. Journal of the American Statistical Association, 22(158), 209–212.

[9] BAAI. bge-reranker-v2-m3 [Model card]. Hugging Face. https://huggingface.co/BAAI/bge-reranker-v2-m3

[10] Google DeepMind. Gemma 4 (gemma-4-E4B-it) [Model card]. Hugging Face. https://huggingface.co/google/gemma-4-E4B-it